我用kafka两年踩过的一些非比寻常的坑

华仔聊技术 5天前

编者荐语：

本篇讲述了苏三大佬在使用kafka踩坑实记，内容非常精彩，大佬实战经验也非常丰富

以下文章来源于苏三说技术 ， 作者因为热爱所以坚持ing

苏三说技术

作者就职于知名互联网公司，掘金月度优秀作者，从事开发、架构和部分管理工作。实...

前言

我的上家公司是做餐饮系统的，每天中午和晚上用餐高峰期，系统的并发量不容小觑。为了保险起见，公司规定各部门都要在吃饭的时间轮流值班，防止出现线上问题时能够及时处理。

我当时在后厨显示系统团队，该系统属于订单的下游业务。用户点完菜下单后，订单系统会通过发 `kafka` 消息给我们系统，系统读取消息后，做业务逻辑处理，持久化订单和菜品数据，然后展示到划菜客户端。这样厨师就知道哪个订单要做哪些菜，有些菜做好了，就可以通过该系统出菜。系统自动通知服务员上菜，如果服务员上完菜，修改菜品上菜状态，用户就知道哪些菜已经上了，哪些还没有上。这个系统可以大大提高后厨到用户的效率。

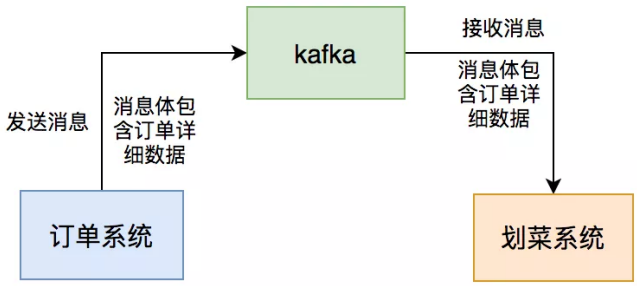

事实证明，这一切的关键是消息中间件： `kafka` ，如果它有问题，将会直接影响到后厨显示系统的功能。

接下来，我跟大家一起聊聊使用 kafka 两年时间踩过哪些坑？

顺序问题

1. 为什么要保证消息的顺序？

刚开始我们系统的商户很少，为了快速实现功能，我们没想太多。既然是走消息中间件 kafka 通信，订单系统发消息时将订单详细数据放在消息体，我们后厨显示系统只要订阅 topic ，就能获取相关消息数据，然后处理自己的业务即可。

不过这套方案有个关键因素：要保证消息的顺序。

为什么呢？

订单有很多状态，比如：下单、支付、完成、撤销等，不可能 下单 的消息都没读取到，就先读取 支付 或 撤销 的消息吧，如果真的这样，数据不是会产生错乱？

好吧，看来保证消息顺序是有必要的。

2.如何保证消息顺序？

我们都知道 kafka 的 topic 是无序的，但是一个 topic 包含多个 partition ，每个 partition 内部是有序的。

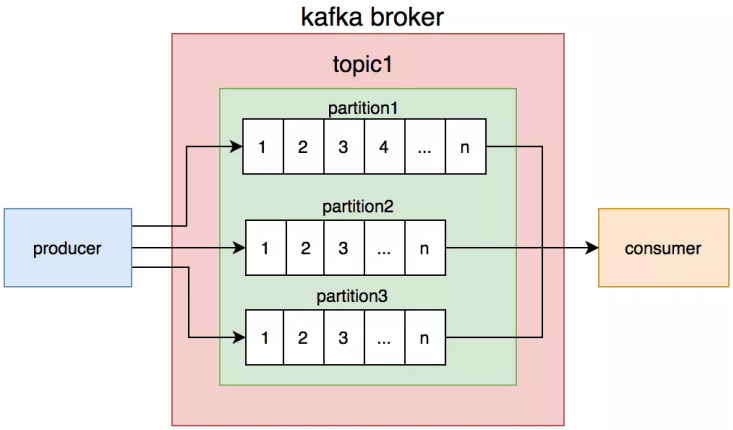

如此一来，思路就变得清晰了：只要保证生产者写消息时，按照一定的规则写到同一个 partition ，不同的消费者读不同的 partition 的消息，就能保证生产和消费者消息的顺

序。

我们刚开始就是这么做的，同一个 商户编号 的消息写到同一个 partition ， topic 中创建了 4 个 partition ，然后部署了 4 个消费者节点，构成 消费者组 ，一个 partition 对应一个消费者节点。从理论上说，这套方案是能够保证消息顺序的。

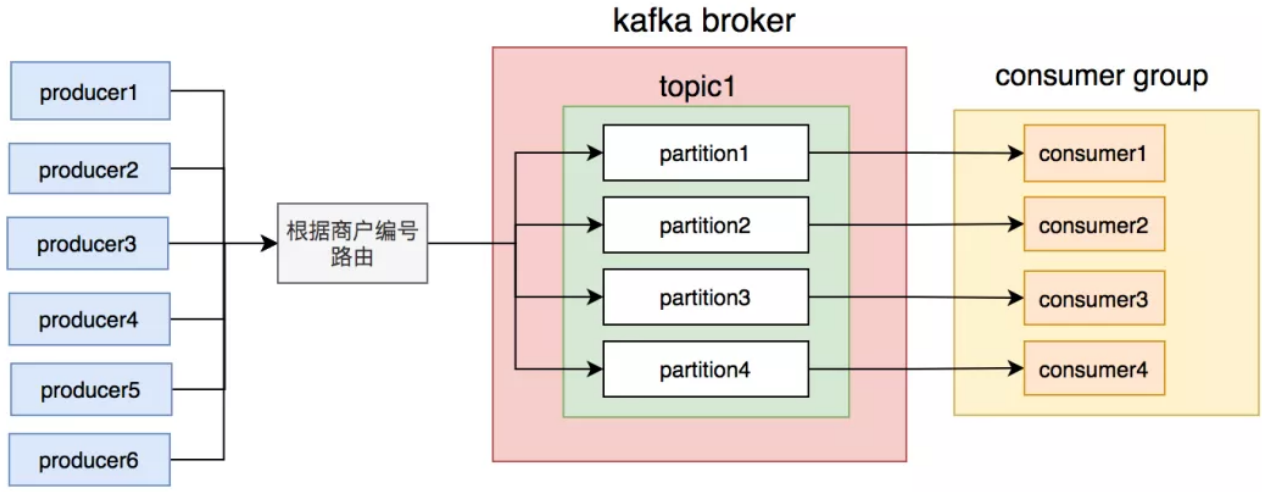

一切规划得看似“天衣无缝”，我们就这样”顺利“上线了。

3.出现意外

该功能上线了一段时间，刚开始还是比较正常的。

但是，好景不长，很快就收到用户投诉，说在划菜客户端有些订单和菜品一直看不到，无法划菜。

我定位到了原因，公司在那段时间网络经常不稳定，业务接口时不时报超时，业务请求时不时会连不上数据库。

这种情况对 顺序消息 的打击，可以说是 毁灭性 的。

为什么这么说？

假设订单系统发了：”下单“、”支付“、”完成“ 三条消息。

而”下单“消息由于网络原因我们系统处理失败了，而后面的两条消息的数据是无法入库的，因为只有”下单“消息的数据才是完整的数据，其他类型的消息只会更新状态。

加上，我们当时没有做 失败重试机制 ，使得这个问题被放大了。问题变成：一旦”下单“消息的数据入库失败，用户就永远看不到这个订单和菜品了。

那么这个紧急的问题要如何解决呢？

4.解决过程

最开始我们的想法是：在消费者处理消息时，如果处理失败了，立马重试3-5次。但如果有些请求要第6次才能成功怎么办？不可能一直重试呀，这种同步重试机制，会阻塞其他商户订单消息的读取。

显然用上面的这种 同步重试机制 在出现异常的情况，会严重影响消息消费者的消费速度，降低它的吞吐量。

如此看来，我们不得不用 异步重试机制 了。

如果用异步重试机制，处理失败的消息就得保存到 重试表 下来。

但有个新问题立马出现：只存一条消息如何保证顺序？

存一条消息的确无法保证顺序，假如：”下单“消息失败了，还没来得及异步重试。此时，”支付“消息被消费了，它肯定是不能被正常消费的。

此时，”支付“消息该一直等着，每隔一段时间判断一次，它前面的消息都有没有被消费？

如果真的这么做，会出现两个问题：

1. ”支付“消息前面只有”下单“消息，这种情况比较简单。但如果某种类型的消息，前面有N多种消息，需要判断多少次呀，这种判断跟订单系统的耦合性太强了，相当于要把他们系统的逻辑搬一部分到我们系统。
2. 影响消费者的消费速度

这时有种更简单的方案浮出水面：消费者在处理消息时，先判断该 订单号 在 重试表 有没有数据，如果有则直接把当前消息保存到 重试表 。如果没有，则进行业务处理，如果出现异常，把该消息保存到 重试表 。

后来我们用 elastic-job 建立了 失败重试机制 ，如果重试了 7 次后还是失败，则将该消息的状态标记为 失败 ，发邮件通知开发人员。

终于由于网络不稳定，导致用户在划菜客户端有些订单和菜品一直看不到的问题被解决了。现在商户顶多偶尔延迟看到菜品，比一直看不菜品好太多。

消息积压

随着销售团队的市场推广，我们系统的商户越来越多。随之而来的是消息的数量越来越大，导致消费者处理不过来，经常出现消息积压的情况。对商户的影响非常直观，划菜客户端上的订单和菜品可能半个小时后才能看到。一两分钟还能忍，半个消息的延迟，对有些暴脾气的商户哪里忍得了，马上投诉过来了。我们那段时间经常接到商户投诉说订单和菜品有延迟。

虽说，加 服务器节点 就能解决问题，但是按照公司为了省钱的惯例，要先做系统优化，所以我们开始了 消息积压 问题解决之旅。

1. 消息体过大

虽说 kafka 号称支持 百万级的TPS ，但从 producer 发送消息到 broker 需要一次网络 IO ， broker 写数据到磁盘需要一次磁盘 IO （写操作）， consumer 从 broker 获取消息先经过一次磁盘 IO （读操作），再经过一次网络 IO 。

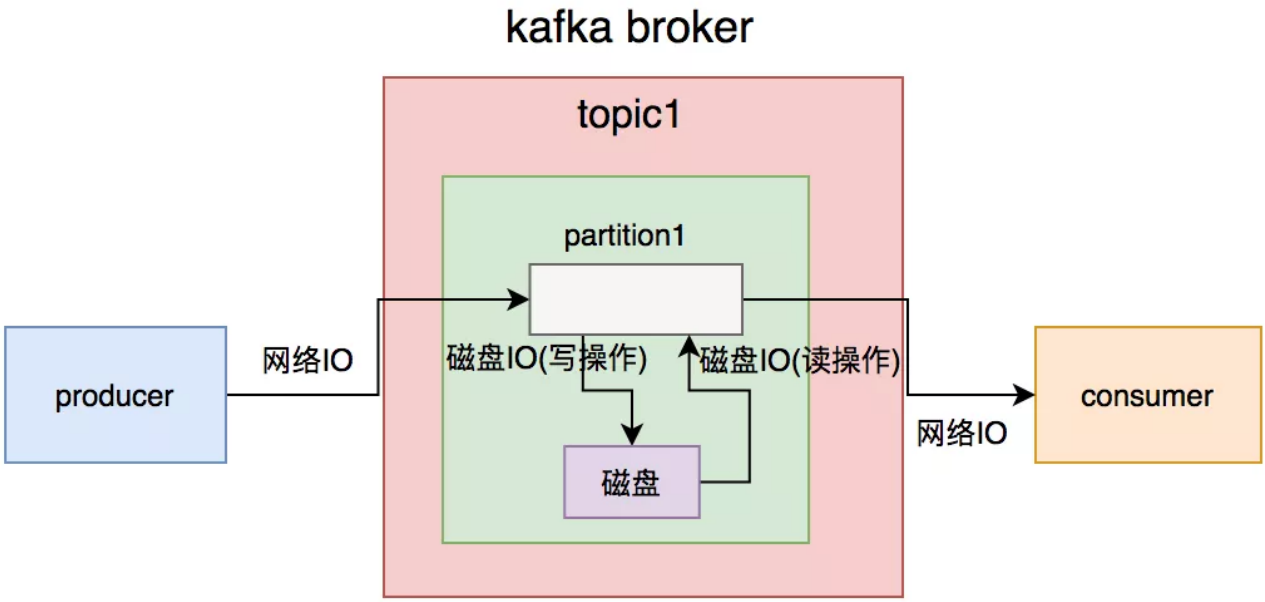

一次简单的消息从生产到消费过程，需要经过 2次网络IO 和 2次磁盘IO 。如果消息体过大，势必会增加IO的耗时，进而影响kafka生产和消费的速度。消费者速度太慢的结果，就会出现消息积压情况。

除了上面的问题之外， 消息体过大 ，还会浪费服务器的磁盘空间，稍不注意，可能会出现磁盘空间不足的情况。

此时，我们已经到了需要优化消息体过大问题的时候。

如何优化呢？

我们重新梳理了一下业务，没有必要知道订单的 中间状态 ，只需知道一个 最终状态 就可以了。

如此甚好，我们就可以这样设计了：

1. 订单系统发送的消息体只用包含：id和状态等关键信息。
2. 后厨显示系统消费消息后，通过id调用订单系统的订单详情查询接口获取数据。
3. 后厨显示系统判断数据库中是否有该订单的数据，如果没有则入库，有则更新。

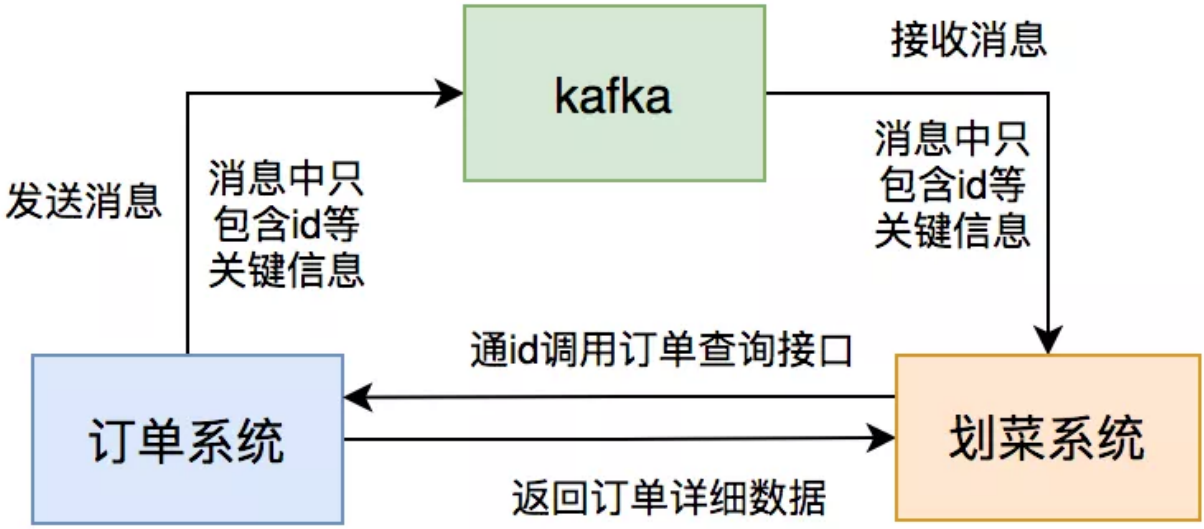

果然这样调整之后，消息积压问题很长一段时间都没再出现。

2. 路由规则不合理

还真别高兴的太早，有天中午又有商户投诉说订单和菜品有延迟。我们一查kafka的topic竟然又出现了消息积压。

但这次有点诡异，不是所有 `partition` 上的消息都有积压，而是只有一个。

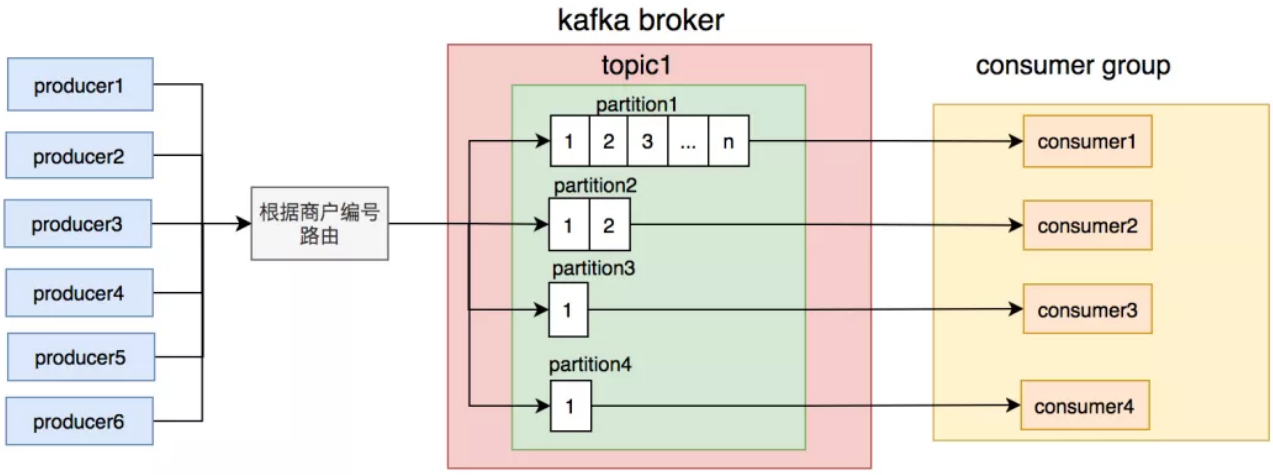

刚开始，我以为是消费那个 `partition` 消息的节点出了什么问题导致的。但是经过排查，没有发现任何异常。

这就奇怪了，到底哪里有问题呢？

后来，我查日志和数据库发现，有几个商户的订单量特别大，刚好这几个商户被分到同一个 partition ，使得该 partition 的消息量比其他 partition 要多很多。

这时我们才意识到，发消息时按 商户编号 路由 partition 的规则不合理，可能会导致有些 partition 消息太多，消费者处理不过来，而有些 partition 却因为消息太少，消费者出现空闲的情况。

为了避免出现这种分配不均匀的情况，我们需要对发消息的路由规则做一下调整。

我们思考了一下，用订单号做路由相对更均匀，不会出现单个订单发消息次数特别多的情况。除非是遇到某个人一直加菜的情况，但是加菜是需要花钱的，所以其实同一个订单的消息数量并不多。

调整后按 订单号 路由到不同的 partition ，同一个订单号的消息，每次到发到同一个 partition 。

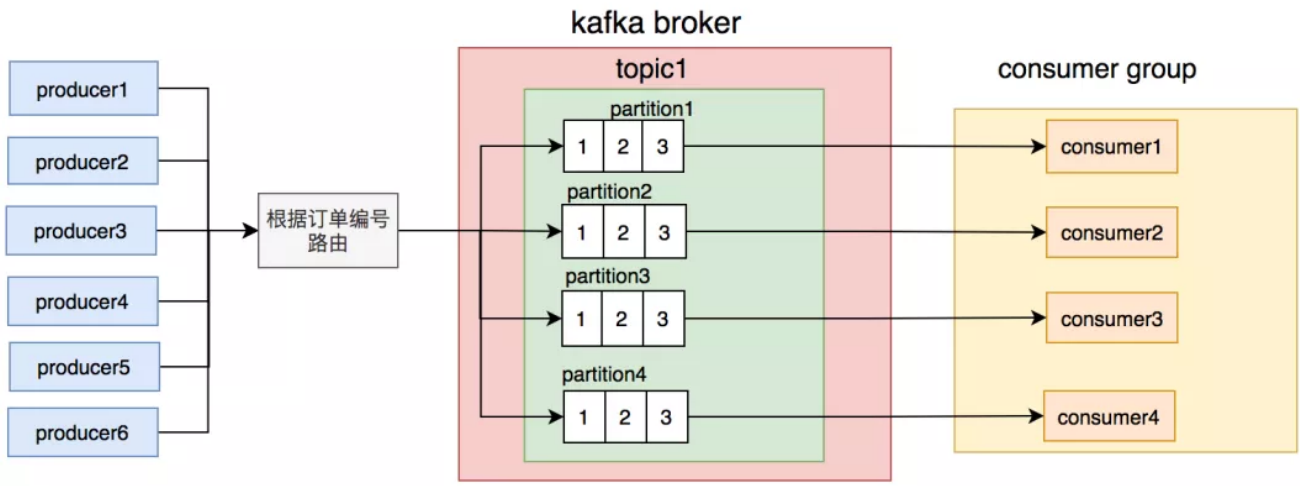

调整后，消息积压的问题又有很长一段时间都没有再出现。我们的商户数量在这段时间，增长的非常快，越来越多了。

3. 批量操作引起的连锁反应

在高并发的场景中，消息积压问题，可以说如影随形，真的没办法从根本上解决。表面上看，已经解决了，但后面不知道什么时候，就会冒出一次，比如这次：

有天下午，产品过来说：有几个商户投诉过来了，他们说菜品有延迟，快查一下原因。

这次问题出现得有点奇怪。

为什么这么说？

首先这个时间点就有点奇怪，平常出问题，不都是中午或者晚上用餐高峰期吗？怎么这次问题出现在下午？

根据以往积累的经验，我直接看了 kafka 的 topic 的数据，果然上面消息有积压，但这次每个 partition 都积压了 十几万 的消息没有消费，比以往加压的消息数量增加了 几百倍 。这次消息积压得极不寻常。

我赶紧查服务监控看看消费者挂了没，还好没挂。又查服务日志没有发现异常。这时我有点迷茫，碰运气问了问订单组下午发生了什么事情没？他们说下午有个促销活动，跑了一个JOB批量更新过有些商户的订单信息。

这时，我一下子如梦初醒，是他们在JOB中批量发消息导致的问题。怎么没有通知我们呢？实在太坑了。

虽说知道问题的原因了，倒是眼前积压的这 十几万 的消息该如何处理呢？

此时，如果直接调大 partition 数量是不行的，历史消息已经存储到4个固定的 partition ，只有新增的消息才会到新的 partition 。我们重点需要处理的是已有的partition。

直接加服务节点也不行，因为 kafka 允许同组的多个 partition 被一个 consumer 消费，但不允许一个 partition 被同组的多个 consumer 消费，可能会造成资源浪费。

看来只有用多线程处理了。

为了紧急解决问题，我改成了用 线程池 处理消息，核心线程和最大线程数都配置成了 50 。

调整之后，果然，消息积压数量不断减少。

但此时有个更严重的问题出现：我收到了报警邮件，有两个订单系统的节点down机了。

不久，订单组的同事过来找我说，我们系统调用他们订单查询接口的并发量突增，超过了预计的好几倍，导致有2个服务节点挂了。他们把查询功能单独整成了一个服务，部署了6个节点，挂了2个节点，再不处理，另外4个节点也会挂。订单服务可以说是公司最核心的服务，它挂了公司损失会很大，情况万分紧急。

为了解决这个问题，只能先把线程数调小。

幸好，线程数是可以通过 `zookeeper` 动态调整的，我把核心线程数调成了 `8` 个，核心线程数改成了 `10` 个。

后面，运维把订单服务挂的2个节点重启后恢复正常了，以防万一，再多加了2个节点。为了确保订单服务不会出现问题，就保持目前的消费速度，后厨显示系统的消息积压问题，

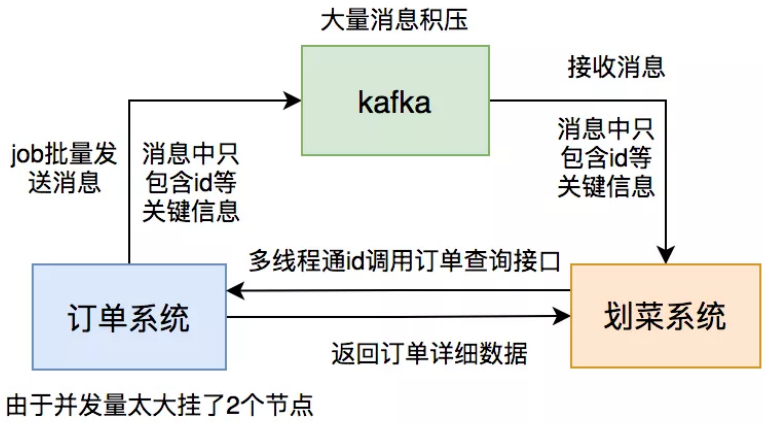

1小时候后也恢复正常了。

后来，我们开了一次复盘会，得出的结论是：

1. 订单系统的批量操作一定提前通知下游系统团队。
2. 下游系统团队多线程调用订单查询接口一定要做压测。
3. 这次给订单查询服务敲响了警钟，它作为公司的核心服务，应对高并发场景做的不够好，需要做优化。
4. 对消息积压情况加监控。

顺便说一下，对于要求严格保证消息顺序的场景，可以将线程池改成多个队列，每个队列用单线程处理。

4. 表过大

为了防止后面再次出现消息积压问题，消费者后面就一直用多线程处理消息。

但有天中午我们还是收到很多报警邮件，提醒我们kafka的topic消息有积压。我们正在查原因，此时产品跑过来说：又有商户投诉说菜品有延迟，赶紧看看。这次她看起来有些不耐烦，确实优化了很多次，还是出现了同样的问题。

在外行看来：为什么同一个问题一直解决不了？

其实技术心里的苦他们是不知道的。

表面上问题的症状是一样的，都是出现了菜品延迟，他们知道的是因为消息积压导致的。但是他们不知道深层次的原因，导致消息积压的原因其实有很多种。这也许是使用消息中间件的通病吧。

我沉默不语，只能硬着头皮定位原因了。

后来我查日志发现消费者消费一条消息的耗时长达 2秒 。以前是 500毫秒 ，现在怎么会变成 2秒 呢？

奇怪了，消费者的代码也没有做大的调整，为什么会出现这种情况呢？

查了一下线上菜品表，单表数据量竟然到了 几千万 ，其他的划菜表也是一样，现在单表保存的数据太多了。

我们组梳理了一下业务，其实菜品在客户端只展示最近 3天 的即可。

这就好办了，我们服务端存着 多余的数据 ，不如把表中多余的数据归档。于是，DBA帮我们把数据做了归档，只保留最近 7天 的数据。

如此调整后，消息积压问题被解决了，又恢复了往日的平静。

主键冲突

别高兴得太早了，还有其他的问题，比如：报警邮件经常报出数据库异常： `Duplicate entry '6' for key 'PRIMARY'` ，说主键冲突。

出现这种问题一般是由于有两个以上相同主键的sql，同时插入数据，第一个插入成功后，第二个插入的时候会报主键冲突。表的主键是唯一的，不允许重复。

我仔细检查了代码，发现代码逻辑会先根据主键从表中查询订单是否存在，如果存在则更新状态，不存在才插入数据，没得问题。

这种判断在并发量不大时，是有用的。但是如果在高并发的场景下，两个请求同一时刻都查到订单不存在，一个请求先插入数据，另一个请求再插入数据时就会出现主键冲突的异常。

解决这个问题最常规的做法是： 加锁 。

我刚开始也是这样想的，加数据库悲观锁肯定是不行的，太影响性能。加数据库乐观锁，基于版本号判断，一般用于更新操作，像这种插入操作基本上不会用。

剩下的只能用分布式锁了，我们系统在用redis，可以加基于redis的分布式锁，锁定订单号。

但后面仔细思考了一下：

1. 加分布式锁也可能会影响消费者的消息处理速度。
2. 消费者依赖于redis，如果redis出现网络超时，我们的服务就悲剧了。

所以，我也不打算用分布式锁。

而是选择使用mysql的 `INSERT INTO ...ON DUPLICATE KEY UPDATE` 语法：

```
INSERTINTOtable (column_list)
VALUES (value_list)
ONDUPLICATEKEYUPDATE
c1 = v1,
c2 = v2,
...;
```

它会先尝试把数据插入表，如果主键冲突的话那么更新字段。

把以前的 `insert` 语句改造之后，就没再出现过主键冲突问题。

数据库主从延迟

不久之后的某天，又收到商户投诉说下单后，在划菜客户端上看得到订单，但是看到的菜品不全，有时甚至订单和菜品数据都看不到。

这个问题跟以往的都不一样，根据以往的经验先看 kafka 的 topic 中消息有没有积压，但这次并没有积压。

再查了服务日志，发现订单系统接口返回的数据有些为空，有些只返回了订单数据，没返回菜品数据。

这就非常奇怪了，我直接过去找订单组的同事。他们仔细排查服务，没有发现问题。这时我们不约而同的想到，会不会是数据库出问题了，一起去找 DBA 。果然， DBA 发现数据库的主库同步数据到从库，由于网络原因偶尔有延迟，有时延迟有 3秒 。

如果我们的业务流程从发消息到消费消息耗时小于 3秒 ，调用订单详情查询接口时，可能会查不到数据，或者查到的不是最新的数据。

这个问题非常严重，会导致直接我们的数据错误。

为了解决这个问题，我们也加了 重试机制 。调用接口查询数据时，如果返回数据为空，或者只返回了订单没有菜品，则加入 重试表 。

调整后，商户投诉的问题被解决了。

重复消费

kafka 消费消息时支持三种模式：

- at most once模式 最多一次。保证每一条消息commit成功之后，再进行消费处理。消息可能会丢失，但不会重复。
- at least once模式 至少一次。保证每一条消息处理成功之后，再进行commit。消息不会丢失，但可能会重复。
- exactly once模式 精确传递一次。将offset作为唯一id与消息同时处理，并且保证处理的原子性。消息只会处理一次，不丢失也不会重复。但这种方式很难做到。

kafka 默认的模式是 at least once ，但这种模式可能会产生重复消费的问题，所以我们的业务逻辑必须做幂等设计。

而我们的业务场景保存数据时使用了 INSERT INTO ...ON DUPLICATE KEY UPDATE 语法，不存在时插入，存在时更新，是天然支持幂等性的。

多环境消费问题

我们当时线上环境分为： pre (预发布环境) 和 prod (生产环境)，两个环境共用同一个数据库，并且共用同一个kafka集群。

需要注意的是，在配置 kafka 的 topic 的时候，要加前缀用于区分不同环境。pre环境的以pre_开头，比如：pre_order，生产环境以prod_开头，比如：prod_order，防止消息在不同环境中串了。

但有次运维在 pre 环境切换节点，配置 topic 的时候，配错了，配成了 prod 的 topic 。刚好那天，我们有新功能上 pre 环境。结果悲剧了， prod 的有些消息被 pre 环境的 consumer 消费了，而由于消息体做了调整，导致 pre 环境的 consumer 处理消息一直失败。

其结果是生产环境丢了部分消息。不过还好，最后生产环境消费者通过重置 offset ，重新读取了那一部分消息解决了问题，没有造成太大损失。

后记

除了上述问题之外，我还遇到过：

- kafka 的 consumer 使用自动确认机制，导致 cpu使用率100% 。
- kafka 集群中的一个 broker 节点挂了，重启后又一直挂。

这两个问题说起来有些复杂，我就不一一列举了，有兴趣的朋友可以关注我的公众号，加我的微信找我私聊。

非常感谢那两年使用消息中间件 kafka 的经历，虽说遇到过挺多问题，踩了很多坑，走了很多弯路，但是实打实的让我积累了很多宝贵的经验，快速成长了。

其实 kafka 是一个非常优秀的消息中间件，我所遇到的绝大多数问题，都并非 kafka 自身的问题（除了cpu使用率100%是它的一个bug导致的之外）。

精选文章推荐：

搞透Kafka的存储架构，看这篇就够了

kafka 核心原理阶段总结篇